

SK네트웍스 Family AI 과정 19기

데이터 전처리 학습된 인공지능 모델

산출물 단계	데이터 전처리
평가 산출물	학습된 인공지능 모델
제출 일자	2026-01-13
깃허브 경로	https://github.com/orgs/Poli-Cheetah
작성 팀원	박준영

1. **모델 목적:** 분할된 문서의 일부분에서 맥락에 알맞는 요약을 생성하는 모델

2. **모델 아키텍처 설계**

- 최종 선정 모델: google/gemma-2-2b-it

모델의 선정에는 distillation을 통한 학습 가능성을 최우선으로 고려하며, 모델의 기본 성능과 사이즈를 중심으로 고려

- 아키텍처 개요:

계층명	역할	구성 요소
Token Embedding	입력 문장을 벡터화	SentencePiece 기반 Subword Tokenizer
Positional Encoding (RoPE)	토큰 간 순서 정보 반영	Rotary Positional Embedding
Transformer Decoder Block	Transformer Decoder Block	RMSNorm (Pre-LN) Grouped Multi-Head Self-Attention Residual Connection RMSNorm SwiGLU FFN Residual Connection
Self-Attention (GQA)	장·단기 문맥 의존성 학습	Query Projection, Key/Value Projection
Feed-Forward Network (FFN)	비선형 변환을 통한 표현력 확장	Linear Projection
Language Modeling Head	다음 토큰 확률 예측	

- 아키텍처 시각화:

Input Tokens



Token Embedding



[Transformer Block × N]

├─ RMSNorm

├─ Grouped Multi-Head Self-Attention (RoPE)

├─ Residual Add

├─ RMSNorm

├─ SwiGLU Feed-Forward

└─ Residual Add



Final RMSNorm



LM Head (Linear)



Logits

3. 모델 학습 요약

- Gemma-2-2b-it와 같은 계열의 상대적 대형 모델인 gemma-2-9b-it를 LoRA를 통해 학습

항목	값
학습 데이터 수	1,014건
검증 데이터 수	200건
에폭(Epoch) 수	3
배치 크기 (Batch Size)	2
학습률 (Learning Rate)	2e-4

- 학습된 gemma-2-9b-it 에서 토큰을 생성할 때의 logit 값을 추출
- Gemma-2-2b-it 모델이 학습 데이터와, 이 데이터에 대한 gemma-2-9b-it 모델의 logits 값을 참고하여 teacher 모델의 target 의 확률 분포를 모방하도록 학습

- 성능 평가 결과:

BERT Score:

지표	값
Precision	81.3%
Recall	83.3%
F1 Score	83.2%

ROUGE Evaluation:

지표	값
ROUGE1	0.478
ROUGE2	0.278
ROUGE2SUM	0.473

- 일반화 성능 평가:
 - 미검증 데이터셋(Test set)에 대한 성능 평가 결과 포함
 - 학습에 사용한 데이터, 학습에 사용한 데이터와 유사하지만 차이가 있는 데이터, 새로 생성한 데이터셋을 혼합하여 사용

4. 저장 및 배포

- 저장 형식:

항목	설명
저장 파일명	/gemma-2-final-summary-model
저장 형식	모델의 학습 파라미터 등이 저장된 폴더
저장 방법	<pre>student_model.save_pretrained("./gemma-2b-final-summary-model") tokenizer.save_pretrained("./gemma-2b-final-summary-model")</pre>
모델 불러오기 코드 예시	<pre>model = AutoModelForCausalLM.from_pretrained(student_model_path, torch_dtype=torch.bfloat16, device_map="auto",)</pre>

- 모델 사양 요구 사항:

- 사용 라이브러리 : peft-0.18.1 accelerate-1.12.0 bitsandbytes-0.49.1 datasets-4.4.2 trl-0.26.2
- GPU/CPU 호환 여부: 학습 시는 GPU 사용 필수, 사용 시에도 GPU 사용 권장

- 모델 테스트:

- 모델 추론 테스트 완료, 적재 진행중
- Inference 예시:

입력: “### RAG(Retrieval-Augmented Generation)의 핵심 구성 요소\n\nRAG 시스템은 크게 세 단계로 나뉩니다. 첫째, 문서 로드 및 청킹(Chunking)을 통한 데이터 준비입니다. 둘째, 사용자 질문을 벡터화하여 관련 문서를 찾는 검색(Retrieval) 단계입니다. 셋째, 검색된 정보와 질문을 결합해 답변을 생성(Generation)하는 단계입니다.”

출력: “RAG 시스템은 문서 로드·청킹과 함께 검색, 생성을 통해 세 단계로 구조화된다.”

5. 종합 평가 및 활용 방안

- 일반화 가능성: 미사용 데이터셋에서도 일정 수준의 성능 유지
- 향후 활용: API 서버에 탑재하여 섹션화된 문서의 일부분을 요약하고, 기존 문서와 비교할 수 있는 데이터를 생성하는 데에 사용

6. 추가 개선 예정 사항

- 추가 데이터셋 수집을 통한 성능 고도화
- 추론 속도 향상을 위한 모델 경량화

7. 추가 기재

- 저장된 모델 파일 위치 또는 URL: `gemma-2b-final-summary-model`